Rapport d'Optimisation et d'Entraînement du Modèle

Projet: SMART Object Detection

Auteur : Fouad Belhia, Ghada Ben Younes et Oumaima Moughazli

Modèle: YOLOv5n (personnalisé: yolo11n.pt)

Date: Juin 2025

1. Objectif

L'objectif de cette série d'expériences est de former un modèle de détection d'objets performant sur un jeu de données industriel pour la reconnaissance de produits. Nous avons cherché à optimiser les performances métriques (mAP50-95, Precision, Recall) en assurant la stabilité et la généralisation du modèle aux scénarios du monde réel, notamment face aux défis rencontrés en production.

2. Stratégie d'optimisation

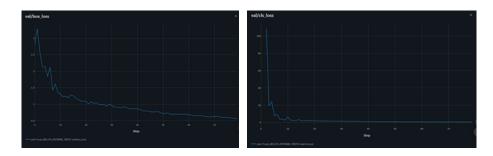
Notre approche a été itérative et incrémentale, guidée par les performances de validation et les retours des tests en production. Chaque test a impliqué la modification d'un ou deux hyperparamètres clés pour isoler leur influence. Nous avons évalué la stabilité (pertes d'entraînement vs validation), l'évolution des métriques de détection, l'impact sur le temps d'entraînement et l'utilisation des ressources. Les problèmes d'inférence en conditions réelles ont fortement orienté les ajustements. Tous les tests ont été suivis dans MLflow.

3. Analyse par hyperparamètre

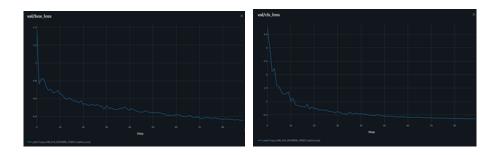
3.1 Nombre d'epochs

L'objectif est de déterminer le nombre d'époques suffisant pour permettre une convergence efficace sans surentraînement.

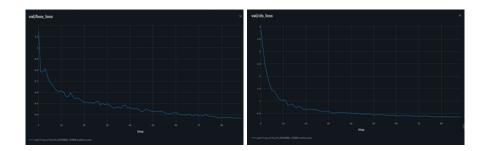
80 Epochs (*yolo11n.pt_e80_b16_20250606_100252*): convergence trop rapide, mAP50-95 = 0.7644, pertes encore en baisse à la fin.



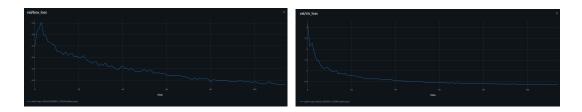
100 Epochs (*yolo11n.pt_e100_b16_20250606_103823*): meilleure performance que le test précédent (mAP ~0.79), mais encore loin de l'optimum.



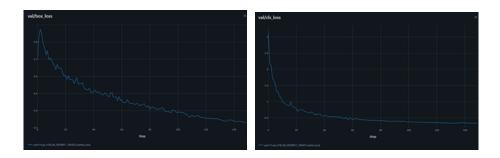
110 Epochs (*yolo11n.pt_e110_b16_20250606_135608*): Ir0 trop faible, mais utile pour observer les tendances de la loss.



130 Epochs (*yolo11n.pt_e130_b8_20250612_152346*): mAP50-95 ~0.88, courbe de validation stable.



150 Epochs (*yolo11n.pt_e150_b8_20250611_185423*): mAP50-95 ~0.90, courbe de validation stable. Meilleur modèle.

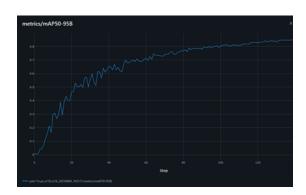


À **150 epochs**, les pertes cessent de diminuer de manière significative mais restent stables. Cela permet à la patience du early stopping de jouer pleinement son rôle, et garantit une convergence plus robuste.

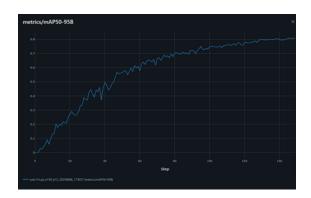
3.2 Taille de lot (batch)

L'objectif est d'évaluer l'impact de la taille de lot sur la stabilité de l'apprentissage et la qualité finale.

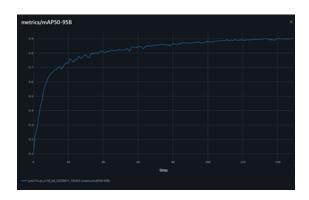
Batch 16 ($yolo11n.pt_e150_b16_20250606_163313$): descente rapide des pertes, mais sur certains runs, tendance à stagner autour de mAP = 0.79 - 0.82.



Batch 12 (*yolo11n.pt_e150_b12_20250606_173027*) : mAP correcte (~0.85), compromis acceptable.



Batch 8 (*yolo11n.pt_e150_b8_20250611_185423*) : pertes les plus faibles, meilleure régularité, mAP=0.9017.

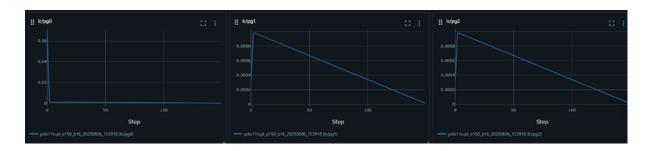


La taille 8 est plus lente, mais permet un meilleur lissage des gradients et donne la meilleure précision sur la tâche SMART.

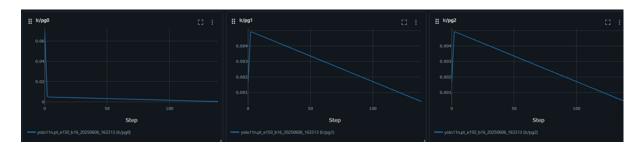
3.3 Taux d'apprentissage initial (Ir0)

L'objectif est de trouver le Ir0 qui maximise la vitesse d'apprentissage sans causer d'instabilité.

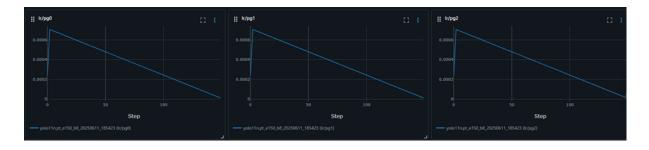
Ir0=0.001 (*yolo11n.pt_e150_b16_20250606_153918*) : correcte mais lente.



Ir0=0.005 ($yolo11n.pt_e150_b16_20250606_163313$): bonnes performances initiales, mais dégradation tardive.



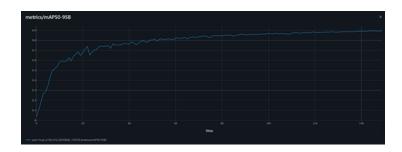
Ir0=0.01 (*yolo11n.pt_e150_b8_20250611_185423*) : descente rapide, sans oscillations excessives, mAP>0.90.



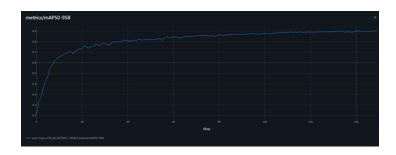
Un Taux d'apprentissage initial de 0.01 s'est avéré optimal uniquement dans le contexte d'un batch de 8 + optimizer auto.

3.4 Optimiseur

AdamW (yolo11n.pt_e150_b16_20250606_153918): pertes plus stables, mais mAP < 0.86.



Auto (*yolo11n.pt_e150_b8_20250611_185423*) : meilleures performances globales (précision, stabilité, mAP).



L'optimiseur auto ajuste dynamiquement les learning rates, ce qui a permis une convergence plus rapide avec un meilleur rappel.

3.5 Usage du cach

cache=True (yolo11n.pt_e100_b16_20250606_103823, yolo11n.pt_e150_b12_20250606_173027): temps d'exécution réduit, mais instabilités mémoire et divergence tardive.

cache=False (*yolo11n.pt_e150_b8_20250611_185423*) : aucun souci mémoire, pertes plus régulières.

Priorité donnée à la stabilité et reproductibilité en production.

3.6 Close Mosaic

close_mosaic=0 (*yolo11n.pt_e150_b8_20250611_083304*) : instabilité visuelle et convergence lente.

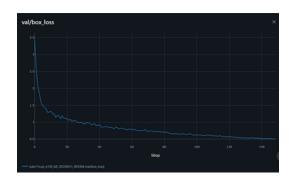
close_mosaic=10 (*yolo11n.pt_e150_b12_20250606_173027*) : peu d'impact significatif.

close_mosaic=15 (*yolo11n.pt_e150_b8_20250611_185423*) : effet régularisateur fort en fin d'apprentissage.

Le run final montre que cette valeur permet de préserver la diversité tout en assurant une stabilisation des prédictions.

3.8 Patience (early stopping)

patience=20 : arrêt prématuré (pertes encore en baisse, ex. *yolo11n.pt* e150 b8 20250611 083304).



patience=50 (yolo11n.pt_e150_b16_20250606_153918): inutilement long

patience=30 (*yolo11n.pt_e150_b8_20250611_185423*) : arrêt sur plateau de validation, mAP stabilisé.

Compromis idéal entre temps de calcul et épuisement du gain marginal.

4. Modèle Final Retenu

Le modèle final retenu pour notre système de détection est yolo11n.pt_e150_b8_20250611_185423. Ce modèle a été entraîné pendant 150 époques avec un batch size de 8, un taux d'apprentissage initial (Ir0) de 0.01, et un optimiseur sélectionné automatiquement. L'entraînement a été réalisé sans mise en cache des données, avec la désactivation du mosaic augmentation à partir de l'époque 15 et une stratégie d'early stopping avec une patience de 30.

En termes de performances, ce modèle a obtenu de très bons résultats avec un mAP50-95 de 0.9017, une précision de 0.9805 et un rappel de 0.9228, ce qui montre une excellente capacité à détecter et classer les objets avec précision. Les pertes associées à la validation sont également maîtrisées, avec une val/box_loss de 0.330, une val/cls_loss de 0.336 et une val/dfl_loss de 0.807, confirmant la stabilité et l'efficacité de l'apprentissage. Ce modèle constitue donc la meilleure version entraînée selon nos critères d'évaluation.

